

期末作业

深度学习与空间智能

三维生成与 ACT 空间智能实验报告

成员	学号	主要分工
钱玲萱	24110980018	题目一物体 A 真实重建与 A/B/C 场景融合
吉张林	25110980010	题目一物体 B、C 的 AIGC 三维生成
朱宇玄	25110980033	题目二 ACT 实验、结果分析与报告整合

GitHub 项目地址:

<https://github.com/MayRainStop/3d-generation-act-spatial-intelligence>

模型权重网盘地址:

https://drive.google.com/drive/folders/14n7YY6TVmrlqI1PM1GP65uwwRv75a2do?usp=drive_link

摘要

本文完成题目一三维重建与 AIGC 生成、题目二具身智能模仿学习两部分实验。题目一按照任务顺序依次完成三类物体构建、Mip-NeRF 360 任务场景重建和 A/B/C 场景融合: 真实物体 A 以湿巾包为对象, 使用 73 张手机多视角图像完成 COLMAP+3DGS 重建; 物体 B 使用 threestudio text-to-3D 生成梨形纹理网格; 物体 C 使用 Zero123 image-to-3D 从单张红黄水果图生成网格。随后在 garden、bicycle 和 counter 三个场景上使用 COLMAP 稀疏相机与官方 3DGS 流程进行重建, 并使用 PSNR、SSIM 和 LPIPS 进行定量评估, 其中 counter 场景主实验取得 PSNR 29.61、SSIM 0.9290、LPIPS 0.1007, garden 场景主实验取得 PSNR 27.86、SSIM 0.8751、LPIPS 0.1027。最终融合阶段将物体 A、梨形物体 B 和单图生成物体 C 插入重建的 counter 背景场景并导出 150 帧环绕漫游视频; garden 步数/分辨率消融和 AIGC 路线示例放在题目一主线之后作为附加分析。题目二完成 LeRobot ACT 在 CALVIN 上的跨环境泛化实验, 比较 A-only 基础策略和 ABC-mixed 多环境联合策略在未见环境 D 上的 zero-shot 表现: 在课程提供的 splitA/splitB/splitC/splitD 官方划分上, A-only 100000 step 取得 Avg Len 0.855, ABC one-hot、ABC SBERT 和 ABC chunk100 分别取得 0.649、0.787 和 0.696; 进一步的 checkpoint sweep 与 seed1 稳健性实验中, ABC SBERT seed1 100000 step 取得 Avg Len 0.923, ABC SBERT seed0 160000 step 取得 0.915; ABC 扩展训练实验在 120000 step checkpoint 取得 Avg Len 1.028。

1 引言

空间智能任务不仅要求模型理解二维图像内容, 还需要恢复或生成三维结构, 并进一步在具身交互环境中学习动作策略。本项目包含两个互相关联的方向: 一方面, 3DGS 和 AIGC 3D 生成关注如何从多视角图像、文本提示或单张图像得到可观察的三维对象与场景; 另一方面, LeRobot ACT 关注如何从机器人示范数据中学习动作序列, 并在新的 CALVIN 环境中进行 zero-shot 泛化。

本文按任务要求的顺序组织题目一。首先构建三类 3D 对象: 真实物体 A 通过手机多视角图像、COLMAP 和 3DGS 重建得到, 物体 B 通过 threestudio text-to-3D 生成梨形纹理网格,

物体 C 通过 Zero123 image-to-3D 从单张图像生成网格。其次，在 Mip-NeRF 360 的 `garden`、`bicycle` 和 `counter` 场景上训练 3D Gaussian Splatting，并在测试视角上评估图像指标。最后，将 A/B/C 三个物体放入重建的 `counter` 背景场景，在 Blender 中统一坐标、材质和相机轨迹并渲染漫游视频。消融实验和额外 AIGC 路线示例集中放在题目一末尾，避免打散主线要求。

LeRobot ACT 部分根据题目要求比较两类策略：仅使用环境 A 数据训练的基础模型，以及混合环境 A、B、C 数据训练的多环境联合模型。为避免用 episode 顺序近似环境标签，本文先用 `huiwon/calvin\_task\_ABC\_D` 与 CALVIN 官方 `scene\_info` 做严格对齐，随后采用课程提供的 `splitA/splitB/splitC/splitD` 显式划分作为最终主结果，并分别构造 A-only 与 ABC-mixed 训练集。

2 3DGS 与 AIGC 三维生成实验

2.1 任务要求与总体路线

题目一包含三个按顺序衔接的要求。首先，需要构建三类三维对象：物体 A 来自真实物体的手机多视角图像，并通过 COLMAP 与 3D Gaussian Splatting 完成重建；物体 B 来自文本提示，使用 threestudio 的 SDS text-to-3D 路线生成；物体 C 来自单张二维图片，使用 Zero123 类 image-to-3D 路线生成。其次，需要在 Mip-NeRF 360 数据集的 `garden`、`bicycle` 和 `counter` 场景上训练 3DGS，并评估新视角渲染质量。最后，需要将前面得到的 A/B/C 三个物体放入重建场景中，在 Blender 中完成统一坐标、材质和相机轨迹设置，并导出漫游视频。

因此，本节严格按题目要求组织：§2.2 说明物体 A/B/C 的构建，§2.3 说明 Mip-NeRF 360 场景重建，§2.4 说明场景融合与视频渲染，§2.5 再集中放置额外消融和 AIGC 路线示例。实验使用单张 NVIDIA GeForce RTX 4090 D GPU 完成，既支持 3DGS 训练，也支持 threestudio 生成实验。

表 1: 题目一任务要求与本文完成情况对应关系

任务要求	本文完成内容
1. 构建三类 3D 对象	物体 A 为湿巾包多视角 COLMAP+3DGS 重建；物体 B 为梨形 text-to-3D 纹理网格；物体 C 为单图 Zero123 路线生成网格
2. Mip-NeRF 360 场景重建	在 <code>garden</code> 、 <code>bicycle</code> 、 <code>counter</code> 上训练 3DGS，报告 PSNR、SSIM、LPIPS 和渲染图
3. A/B/C 与场景融合	以 <code>counter</code> 表面网格为背景，在 Blender 中导入 A/B/C 并导出 150 帧环绕视频

2.2 物体 A/B/C 的三维构建

物体 A/B/C 分别对应真实重建、文本生成和单图生成三条路线。物体 A 选取一包湿巾作为真实物体，共采集 73 张 800×450 手机图像；处理时先执行 COLMAP 特征匹配、稀疏重建和 undistortion，得到 5293 个稀疏三维点，再将 undistorted 图像和 `sparse/0` 相机输入 3DGS 训练，训练到 7000 iterations 后导出 146445 个 Gaussian centers。物体 B 使用 threestudio 的 DreamFusion/SDS 配置，由文本 prompt 控制为梨形物体，重点约束 `yellow-green skin`、`red blush`、`speckles` 和 `pear silhouette`，最终导出梨形纹理网格。物体 C 使用单张红黄渐变水果图片作为输入，通过 Zero123 类新视角约束优化并导出单图生成网格。

图 1 将 A/B/C 的来源、构建后的三维资产和融合视频中的对应位置放在同一张图中。这样可以直接看到三条路线的差异：A 的几何来自真实图像和 COLMAP 相机，B 的形状来自文

表 2: 物体 A/B/C 构建路线与最终资产形态

物体	构建方法	最终形态
A	手机多视角拍摄湿巾包, COLMAP 稀疏重建后训练 3DGS	真实物体 3DGS 点云与整理后的湿巾网格
B	threestudio text-to-3D, SDS loss 优化梨形 prompt	带绿色纹理和梨形轮廓的生成网格
C	Zero123 image-to-3D, 以单张红黄水果图为输入	单图生成的红黄纹理网格

本 prompt 与 SDS 优化, C 的颜色和外形主要继承单图输入。图中第三行从融合视频第 30 帧裁剪得到, 用于说明最终视频中 A/B/C 确实都被放入 `counter` 背景场景。

Object A/B/C construction sources, intermediate assets, and fusion video evidence




图 1: 物体 A/B/C 的来源、三维资产与融合视频对应位置。A 为真实湿巾包重建, B 为梨形 text-to-3D 网格, C 为单图生成网格。

真实物体 A 的 3DGS 训练日志保留了逐 step 的损失标量。图 2 展示了 `total\_loss` 与 `l1\_loss` 的变化: `total\_loss` 从第 1 step 的 0.1894 降至第 7000 step 的 0.0186, `l1\_loss` 从 0.1790 降至 0.0136。约 3000 和 6000 step 附近的短时尖峰后, 曲线能迅速回到下降轨迹, 说明自采物体 A 的 COLMAP+3DGS 训练已经形成稳定收敛趋势。



图 2: 真实物体 A 的 3DGS 训练 loss 曲线

图 3 进一步展示了真实物体 A 的采集和重建细节。左侧为手机多视角图像样例，可以看到物体主体在不同方位下均被覆盖；中间为 COLMAP 稀疏点云，主要恢复出物体外轮廓和局部纹理结构；右侧为 3DGS 训练后的高斯中心分布，相比稀疏点云更密集，能够作为后续几何资产整理和 Blender 融合的输入。该实验从自采图像出发完成 COLMAP、undistortion、3DGS 训练和点云导出，形成了完整的真实物体 A pipeline。

Object A phone capture, COLMAP alignment, and 3DGS reconstruction




图 3: 真实物体 A 的手机采集、COLMAP 稀疏重建与 3DGS 点云结果

2.3 Mip-NeRF 360 任务场景重建

场景重建部分使用 Mip-NeRF 360 数据集中的 **garden**、**bicycle** 和 **counter**。每个场景都包含原始图像、下采样图像和 COLMAP 稀疏重建结果。本文采用数据集附带的 COLMAP 相机与稀疏点云文件，使用官方 3DGS 训练代码读取这些文件完成训练，并在测试视角上计算 PSNR、SSIM 和 LPIPS。该部分对应题目一中的“任务场景重建”要求。

表 3: Mip-NeRF 360 场景与 COLMAP 文件检查

场景	原始图像数	下采样图像数	COLMAP sparse/0 文件
garden	185	185	cameras.bin, images.bin, points3D.bin, points3D.ply
bicycle	194	194	cameras.bin, images.bin, points3D.bin, points3D.ply
counter	240	240	cameras.bin, images.bin, points3D.bin, points3D.ply

3D Gaussian Splatting 将场景表示为一组可学习的三维高斯。每个高斯包含中心位置、尺度、旋转、不透明度和颜色相关参数。渲染时，模型将这些三维高斯投影到目标相机平面，并通过 alpha blending 合成图像。官方 3DGS 训练中使用图像重建损失优化场景参数，整体损失为

$$\mathcal{L} = (1 - \lambda)\mathcal{L}_1 + \lambda\mathcal{L}_{D-SSIM}, \quad (1)$$

其中 $\mathcal{L}_1$ 约束像素级重建误差， $\mathcal{L}_{D-SSIM}$ 约束结构相似性。主实验对三个场景均训练 30000 iterations，图像分辨率下采样倍率为 4。

表 4: 3DGS 实验配置

项目	设置
代码库	Official 3D Gaussian Splatting
数据集	Mip-NeRF 360 garden, bicycle, counter
输入几何	COLMAP sparse camera/point files
训练设备	NVIDIA GeForce RTX 4090 D, 24GB
主实验 iterations	30000
主实验下采样倍率	4
评价指标	PSNR, SSIM, LPIPS

表 5 给出了三个场景的主结果。**counter** 场景在三项指标中表现最好，PSNR 达到 29.61，SSIM 达到 0.9290，LPIPS 降到 0.1007；**garden** 场景也取得稳定重建效果；**bicycle** 场景指标相对较低，说明细长结构、遮挡和复杂纹理会增加 3DGS 新视角重建难度。

表 5: 3DGS 定量评价结果

配置	场景	PSNR $\uparrow$	SSIM $\uparrow$	LPIPS $\downarrow$
30000 steps, 下采样倍率 4	bicycle	25.6565	0.7794	0.2024
30000 steps, 下采样倍率 4	counter	29.6144	0.9290	0.1007
30000 steps, 下采样倍率 4	garden	27.8553	0.8751	0.1027

图 4、图 5 和图 6 分别展示三个主场景的测试视角渲染结果。每张 contact sheet 中交替展示真实图像和渲染图像，便于观察局部结构、颜色和视角一致性。**counter** 的桌面、柜体和室内背景结构较稳定，与最高 SSIM 和较低 LPIPS 相符；**garden** 的地面和植被整体恢复较好，但局部植被细节会出现模糊；**bicycle** 中车轮、辐条和背景细纹理更容易产生不稳定渲染。




图 4: garden 主实验测试视角渲染结果



图 5: counter 主实验测试视角渲染结果



图 6: bicycle 主实验测试视角渲染结果

2.4 A/B/C 与重建场景融合

场景融合阶段使用 counter 场景的 3DGS 采样点云进行 Poisson surface reconstruction, 得到可导入 Blender 的背景 mesh。随后将物体 A 的湿巾模型、物体 B 的绿色梨形纹理网格和物体 C 的单图生成网格导入 Blender, 并统一设置位姿、缩放、顶点颜色和贴图材质。最终渲染脚本使用固定中心环绕和先近后远的相机轨迹, 导出 150 帧、24 fps、1280×720 的 H.264 MP4 视频。

2.4.1 3DGS 点云与 AIGC Mesh 的处理

融合阶段首先需要分别处理两类三维资产。3DGS 重建资产的原始表达是高斯基元, 适合新视角渲染, 但不适合直接和传统 OBJ 网格在 Blender 中共同计算遮挡、材质和相机漫游。因此本文先从 3DGS 最终模型导出高斯中心或采样点云, 保留空间坐标和颜色信息; 随后使用 Open3D 对点云估计 KNN 邻域法向, 并通过 Poisson 曲面重建生成连续三角网格。Poisson 重建后再依据顶点密度去除低置信度边缘区域, 并用连通域筛选减少孤立碎片, 最后导出 PLY/OBJ 网格作为 Blender 背景或真实物体资产。

AIGC 生成资产的处理方式不同。物体 B 和物体 C 已经由 text-to-3D 或 image-to-3D 流程导出为多边形网格, 因此不再进行 Poisson 曲面重建, 而是保留其 OBJ 几何和纹理图像, 在 Blender 中完成坐标、朝向、尺度和材质绑定。物体 B 使用生成的梨形网格和纹理贴图, 物体 C 使用单图生成网格和对应纹理贴图; 二者通过 Image Texture 节点接入 Principled BSDF, 从而保持 AIGC 资产原本的纹理外观。

表 6: 异构三维资产到统一 mesh 表达的转换流程

阶段	实际处理
3DGS 场景/物体	高斯中心或采样点云 → 法向估计 → Poisson 曲面重建 → 密度裁剪与连通域筛选 → 顶点颜色 mesh
AIGC 物体 B/C	text-to-3D 或 image-to-3D 导出的 OBJ mesh → 坐标和尺度对齐 → 纹理贴图绑定 → 纹理 mesh
Blender 统一输入	背景、物体 A、物体 B、物体 C 均以 mesh 对象进入同一场景, 差异只保留在材质来源上

2.4.2 统一表达形式与联合渲染

完成上述转换后, 所有资产都以 mesh 形式进入 Blender, 但材质来源保留各自特点。对于场景 surface mesh, 脚本将采样点云颜色通过最近邻映射写入 `mesh.vertex\_colors`; 对于物体 A 的 3DGS PLY, 整理过程读取低阶球谐颜色分量并按 $0.5 + C_0 f_{dc}$ 恢复基础颜色, 其中 $C_0 = 0.2820947918$, 再写入顶点颜色属性。Blender 渲染脚本对 `TABLE` 和 `tissue` 调用顶点颜色材质, 对 `Obj\_B` 和 `Obj\_C` 绑定纹理图像; 因此四类资产能够共享同一坐标系、同一相机轨迹和同一 Cycles 光照环境, 并在视频中形成统一的遮挡关系。

图 7 抽取了视频中的六个关键帧, 可以看到三个物体被放置在重建背景上, 并且环绕视角能展示它们相对背景的空间位置。该结果对应题目一要求中的“将 A/B/C 放入重建背景场景并生成漫游视频”。

表 7: A/B/C 场景融合视频设置

项目	设置与结果
背景场景	使用 counter 的 3DGS 采样点云重建 Poisson surface mesh
物体 A	真实湿巾包 COLMAP+3DGS 重建资产
物体 B	text-to-3D 梨形纹理网格
物体 C	Zero123 单图生成网格
坐标与材质	A/B/C 与背景 mesh 在 Blender 中统一坐标摆放，并绑定顶点颜色或贴图材质
漫游视频	150 frames, 24 fps, 1280×720, H.264 MP4




图 7: Blender 中将物体 A、梨形物体 B 和单图生成物体 C 插入重建 counter 背景后的漫游视频抽帧

2.5 消融实验与结果讨论

除题目一主线要求外，本文还整理了训练步数、下采样倍率、点云/网格导出和 AIGC 路线示例，用于解释重建质量和生成路线。这些内容不中断前面三项任务，因此集中放在本节。

首先，garden 场景的训练步数消融显示，更长训练可以稳定改善图像质量。随着训练步数从 7000 增加到 30000，PSNR 从 26.62 提升到 27.86，SSIM 从 0.8395 提升到 0.8751，LPIPS 从 0.1528 降到 0.1027。下采样倍率 8 的指标更高，但这是在更低分辨率下得到的结果，说明低分辨率更容易拟合，并不代表高频细节一定优于下采样倍率 4。

表 8: garden 场景训练步数与分辨率消融实验

配置	PSNR ↑	SSIM ↑	LPIPS ↓
7000 steps, 下采样倍率 4	26.6160	0.8395	0.1528
15000 steps, 下采样倍率 4	27.3543	0.8657	0.1142
30000 steps, 下采样倍率 4	27.8553	0.8751	0.1027
30000 steps, 下采样倍率 8	29.7440	0.9252	0.0548

其次，为了从三维资产角度检查 3DGS 输出，本文将三个主场景最终模型中的高斯中心采样为点云，并进一步用 Poisson surface reconstruction 生成表面网格。图 10 和图 11 展示了点云和网格结果。它们不替代新视角图像指标，但能进一步说明重建结果已经被整理成 Blender 中可观察的三维资产。



图 8: garden 场景不同训练步数下的渲染对比




图 9: garden 下采样倍率 8 的低分辨率训练与渲染结果




图 10: 最终 3DGS 点云的 Blender 多视角展示




图 11: 最终 3DGS 表面网格的 Blender 多视角展示

最后，报告保留了一组 AIGC 生成路线示例，如图 12 所示。该示例用于展示 threestudio SDS 与 Zero123 两条生成路线的可复现流程，帮助说明 text-to-3D 和 image-to-3D 的输出形式。




图 12: text-to-3D 与 image-to-3D 生成路线示例

从结果看，真实多视角监督和生成式先验解决的是两个不同问题。3DGS 依赖多视角图像、相机位姿和稀疏几何输入，能够得到稳定、可度量的场景重建结果；AIGC 三维生成依赖文本或图像条件，适合在给定概念或单图条件下快速得到三维资产草图。最终融合部分把二者连接起

来，重点体现从真实采集、生成资产、场景重建到 Blender 漫游视频的完整链路。

3 LeRobot ACT 策略学习实验

3.1 基础策略训练

题目二首先要求在 CALVIN 环境 A 上训练一个基础 ACT 策略。该策略只使用 `splitA` 数据，作用是建立单环境视觉-动作基线；后续 ABC-mixed 策略、chunk size 实验和条件输入实验都与它使用同一套评测协议，从而保证 zero-shot 对比有明确参照。

实验使用 LeRobot 格式的 CALVIN ABC-D 数据。为保证环境标签来源明确，本文先核验 `huiwon/calvin_task_ABC_D` 中的 `original\_frame\_idx` 与 CALVIN 官方 `task\_ABC\_D` 的 `scene\_info` 区间对应关系，并据此得到 scene-info 对齐的 A/B/C 标签。最终主分析采用 `xiaoma26/calvin-lerobot` 的显式划分数据：`splitA`、`splitB`、`splitC` 和 `splitD` 分别对应四个环境，其中 `splitA` 用于基础策略训练，`splitA/B/C` 合并后用于混合策略训练，`splitD` 只用于 zero-shot 评测。该数据中 `splitA` 含 6089 个 episode、366693 帧，`splitB` 含 6115 个 episode、367096 帧，`splitC` 含 5666 个 episode、337954 帧，`splitD` 含 5124 个 episode、308918 帧。




图 13: 课程提供的 CALVIN splitA/B/C/D 数据规模

图 13 展示了主分析所用 split 的数据规模。A/B/C 三个训练环境的 episode 数和帧数接近，D 测试环境略小；因此基础策略和混合策略的差异主要来自训练环境覆盖范围、任务条件表示和训练过程，而不是某个 split 的数量级差异。

3.2 混合策略训练

混合策略训练对应题目二的第二个核心要求：将 `splitA`、`splitB` 和 `splitC` 合并为 ABC-mixed 数据集，并在相同 ACT 框架下训练多环境策略。合并时，本文将三个 split 中的任务编号映射到同一套任务语义索引，避免相同任务在不同环境中编号不一致。模型输入包括 static camera、wrist camera、机器人状态和 task condition，输出为 7 维连续动作。

表 9 给出了基础策略和混合策略共用的主要训练设置。ACT (Action Chunking Transformer) 不是逐步预测单个动作，而是在每个观测下预测一段未来动作序列；主实验采用 chunk




图 14: CALVIN ABC 训练集有序划分的图像抽样检查

size 50。为公平比较 A-only 与 ABC-mixed，二者使用相同网络结构、batch size、学习率、优化器、动作维度和在线评测环境。除主对比外，本文还加入更长训练、不同 chunk size、语言条件和错误条件输入等实验，用于分析性能差异来自数据混合、条件表示还是 checkpoint 选择。

表 9: LeRobot ACT 主要训练设置

项目	设置
数据集	CALVIN ABC-D LeRobot 格式数据
策略模型	ACT
Network architecture	CNN visual encoders + Transformer policy + action chunk decoder
观测	Static camera, wrist camera, robot state, task one-hot
动作维度	7
Batch size	8
Optimizer	AdamW
Learning rate	0.0001
Epochs / steps	step-based training, 主实验 50000/100000 steps
扩展训练步数	120000-200000 checkpoint sweep, seed1 robustness check
Loss function	Action L1 loss for continuous 7D action prediction
主实验 chunk size	50
评价环境	CALVIN D zero-shot online evaluation




图 15: 不同 ACT 实验训练过程中的 loss 曲线

图 15 根据训练日志中的 step-loss 记录绘制；训练时采用 `WANDB\_MODE=offline` 保存离线

记录，并从本地日志导出报告曲线。图中使用 5 点滑动平均减少短期抖动，包含显式 split 主实验、ABC 扩展训练、A-only/SBERT 的 160000 step sweep，以及 seed1 稳健性训练。各模型的训练 loss 在前期快速下降，随后进入较平缓阶段。由于训练 loss 只反映示范动作拟合程度，后续仍需结合 CALVIN D 在线评测、任务条件表示和 checkpoint 选择判断真实泛化能力。

3.3 Zero-shot 测试与成功率对比

Zero-shot 测试阶段不再使用环境 D 的训练数据，而是把 A-only 和 ABC-mixed 策略直接部署到 CALVIN D。在线评测以连续完成子任务的长度作为主要指标。Avg Len 表示平均成功子任务数，SR@1 到 SR@5 分别表示至少完成 1 到 5 个连续子任务的比例。表 10 给出了与题目要求最直接对应的 A-only 与 ABC-mixed 对比。

表 10: A-only 与 ABC-mixed ACT 在 CALVIN D 上的 zero-shot 对比

模型	Steps	Chunk	Avg Len	SR@1	SR@2	SR@3	SR@5
huiwon A-only	50000	50	0.288	0.229	0.048	0.011	0.000
huiwon ABC-mixed	50000	50	0.278	0.236	0.037	0.005	0.000
huiwon A-only	100000	50	0.407	0.316	0.078	0.013	0.000
huiwon ABC-mixed	100000	50	0.303	0.242	0.056	0.005	0.000
splitA A-only	100000	50	0.855	0.525	0.225	0.072	0.008
splitABC one-hot	100000	50	0.649	0.402	0.165	0.052	0.009
splitABC SBERT	100000	50	0.787	0.477	0.195	0.071	0.012
splitA A-only seed1	100000	50	0.846	0.487	0.219	0.088	0.011
splitABC SBERT seed1	100000	50	0.923	0.496	0.235	0.112	0.021
splitA A-only sweep	160000	50	0.774	0.482	0.185	0.069	0.009
splitABC SBERT sweep	160000	50	0.915	0.483	0.261	0.104	0.022
ABC extended 120k	120000	50	1.028	0.561	0.277	0.119	0.022

在 scene-info 对齐数据上，A-only 与 ABC-mixed 使用相同 ACT 结构、训练预算和 chunk size 50。50000 step 主实验中，A-only 的 Avg Len 为 0.288，ABC-mixed 为 0.278；继续训练到 100000 step 后，A-only 提升到 0.407，ABC-mixed 提升到 0.303。在显式 split 数据上，splitA A-only 的 Avg Len 为 0.855，直接合并 A/B/C 的 one-hot ABC-mixed 为 0.649；将任务条件由 one-hot 换为 SBERT 文本向量后，ABC-mixed 提升到 0.787。这组结果说明，简单混合 A/B/C 数据并不必然优于 A-only，混合策略是否有效还取决于任务条件的表达方式。

进一步的扩展实验用于检查上述结论是否受 seed 和 checkpoint 影响。SBERT ABC 的 seed1 100000 step 达到 0.923，seed0 160000 step 达到 0.915，而 A-only seed1 为 0.846，A-only 160000 step 为 0.774。ABC 扩展训练在 120000 step checkpoint 达到 Avg Len 1.028，是本文保存的最佳 CALVIN D 在线评测结果。由此可见，任务语义表示、checkpoint 选择和随机种子都会显著影响 D 环境 zero-shot 表现，单次训练结果不能完全代表混合策略的稳定上限。

图 16 将表 10 中的 Avg Len、SR@1 和 SR@5 放在同一张图中。可以看到，Avg Len 的提升并不等价于长任务链完全稳定：例如 splitABC SBERT seed1 的 Avg Len 达到 0.923，SR@1 接近 0.50，但 SR@5 仍只有 0.021。图 17 进一步显示，所有策略从 SR@1 到 SR@3 都快速下降，说明 ACT 已经能在 D 环境完成一部分短程子任务，但一旦需要连续完成多个子任务，误差积累、任务切换和视觉偏移仍然会显著降低成功率。

表 11 比较相同 100000 step 预算下的 seed0 与 seed1。A-only 的两个 seed 非常接近，说明单环境基线较稳定；ABC SBERT 的均值与 A-only 接近，其中 seed1 明显优于 seed0。结合 seed0 160000 step 的 0.915，可以看到 SBERT 条件的 ABC 策略在合适 checkpoint 下可以达




图 16: 主要 ACT 策略在 CALVIN D 上的 Avg Len 与成功率对比




图 17: 不同策略的连续成功深度曲线

表 11: 课程显式 split 100000 step seed 稳健性整理

策略	Condition	Seed0	Seed1	Mean	Sample Std
splitA A-only	one-hot	0.855	0.846	0.8505	0.0064
splitABC SBERT	SBERT	0.787	0.923	0.8550	0.0962

到更高 Avg Len。




图 18: 课程显式 split 上 A-only 与 ABC SBERT 的 seed 稳健性




图 19: 课程显式 split 上 checkpoint sweep 的 Avg Len 变化

图 18 和图 19 显示，A-only 的均值和方差更稳定；ABC SBERT 的均值略高、方差更大，因此多环境策略需要同时报告 seed 和 checkpoint。ABC SBERT seed0 在更长训练后提升到 0.915，说明语言语义条件在足够训练和合适 checkpoint 下能够缓解直接混合 A/B/C one-hot 数据带来的干扰。

3.4 ACT 动作分块机制

ACT 的核心机制是一次预测未来动作片段，而不是每一步只输出一个动作。动作分块长度会同时影响动作平滑性和闭环纠错频率：chunk 太短时策略更频繁地重新规划，容易放大视觉

扰动；chunk 太长时动作片段更完整，但错误也可能持续更久。表 12 汇总了 chunk size、任务条件和训练时长相关实验。

表 12: ACT 扩展实验在 CALVIN D 上的结果

配置	Condition	Avg Len	SR@1	SR@5
Unconditioned ACT	none	0.097	0.094	0.000
Task-conditioned ACT	one-hot	0.671	0.411	0.006
Language-conditioned ACT	SBERT	0.688	0.434	0.009
Language-conditioned ACT	hash	0.492	0.373	0.001
Task-conditioned, chunk 10	one-hot	0.523	0.323	0.007
Task-conditioned, chunk 100	one-hot	0.791	0.517	0.004
Task-conditioned, wrong one-hot	wrong	0.076	0.075	0.000
Task-conditioned, zero one-hot	zero	0.034	0.033	0.000
ABC extended 200k ckpt120k	one-hot	1.028	0.561	0.022
splitABC SBERT 100k	SBERT	0.787	0.477	0.012
splitABC chunk100 100k	one-hot	0.696	0.457	0.008
splitABC SBERT seed1 100k	SBERT	0.923	0.496	0.021
splitABC SBERT seed0 160k	SBERT	0.915	0.483	0.022
splitA A-only seed1 100k	one-hot	0.846	0.487	0.011
splitA A-only seed0 160k	one-hot	0.774	0.482	0.009

动作分块实验显示，chunk size 对跨环境泛化有明显影响。ABC 扩展训练数据上，chunk 10 的 Avg Len 为 0.523；chunk 100 的 Avg Len 为 0.791，SR@1 达到 0.517。显式 split 上的 splitABC chunk100 得到 Avg Len 0.696，同 split 的 SBERT 条件模型得到 0.787。checkpoint sweep 显示，默认 chunk 50 配合 SBERT 条件和合适 checkpoint 是当前结果中更有效的组合：SBERT seed1 100000 step 和 seed0 160000 step 分别达到 0.923 和 0.915。因此，Action Chunking 的作用主要体现在短序列成功率、动作平滑性和误差传播方式之间的平衡。

任务条件消融进一步说明，ACT 在 CALVIN 多任务数据中需要明确的任务目标。未使用 task condition 的模型在 D 上 Avg Len 只有 0.097；错误 one-hot 和零 one-hot 的结果也明显偏低。相比之下，正常 one-hot、SBERT 条件和经过 checkpoint 选择的 SBERT 模型均有更高在线表现，说明条件输入不是附加装饰，而是策略区分不同任务动作意图的必要信息。

3.5 视觉分布偏移分析

Visual Distribution Shift 分析关注训练环境与 D 测试环境在图像观测上的差异，以及这种差异是否能直接解释 zero-shot 成功率。表 13 给出了不同数据划分与环境 D 之间的视觉距离，并同时统计动作序列平滑性。RGB L2 越低表示与 D 的平均视觉差异越小；Mean action delta 和 P95 action delta 描述相邻动作变化幅度。

表 13: Visual distribution shift 与动作平滑性统计

数据划分	RGB L2 top→D	RGB L2 wrist→D	Mean action delta	P95 action delta
A	0.0288	0.0262	0.2260	0.5671
B	0.0263	0.0267	0.2257	0.5665
C	0.0199	0.0270	0.2237	0.5599
ABC	0.0250	0.0265	0.2251	0.5646

从视觉统计看，C 段的 top-view RGB 距离 D 最近；但在显式 split 单环境训练中，C-only




图 20: 训练 split 到环境 D 的视觉距离与动作平滑性

的 Avg Len 为 0.473, A-only 为 0.855。这说明平均视觉距离只是策略泛化的一个因素, 不能单独解释在线成功率。任务覆盖、动作分布、局部交互状态以及训练数据多样性都会影响 D 环境表现。ABC-mixed 整合了更多环境变化; ABC 扩展训练的长训练和 checkpoint sweep 结果更高, 说明数据规模、任务覆盖、训练时长和 checkpoint 选择仍然是影响性能的重要因素。

图 20 显示同样趋势: C 的 top-view RGB 距离最小, 但 wrist-view 距离并不最小, 且单环境策略表现还受到动作先验和任务覆盖影响。这说明 CALVIN 策略泛化需要结合腕部相机、机器人状态、动作先验和任务语义共同分析。




图 21: splitABC SBERT seed1 最终策略的子任务行为分解

在视觉偏移之外, 长任务链还受不同子任务难度影响。本文进一步解析 splitABC SBERT seed1 的评测明细。图 21 显示, 抽屉开合、放入抽屉和滑块移动类动作成功率较高; 积木旋转、从滑块处取放物体和堆叠类动作对接触、姿态调整和连续纠错要求更高。该分析解释了为什么整体 Avg Len 能接近 1, 而 SR@3-SR@5 更依赖长链任务中的精细接触控制。

4 结论

本文完成题目一的三类物体构建、Mip-NeRF 360 场景重建和 A/B/C 场景融合。物体 A 使用 73 张手机多视角图像完成 COLMAP+3DGS 重建, 得到 5293 个 COLMAP 稀疏点和 146445 个 Gaussian centers; 物体 B、C 分别由 threestudio text-to-3D 和 Zero123 image-to-3D 生成。三个 Mip-NeRF 360 场景均完成 3DGS 训练与定量评价, 其中 **counter** 主实验达到 PSNR 29.6144、SSIM 0.9290、LPIPS 0.1007。最终融合阶段将 A/B/C 与 **counter** 背景统一转换或导入为 mesh, 在 Blender 中完成材质、坐标和相机轨迹设置, 并导出 150 帧漫游视频。

题目二完成 LeRobot ACT 的基础策略训练、混合策略训练和 D 环境 zero-shot 测试。splitA A-only 在 100000 step 达到 Avg Len 0.855, splitABC one-hot、SBERT 和 chunk100 分别为 0.649、0.787 和 0.696; seed 与 checkpoint 实验中, splitABC SBERT seed1 100000 step 达到 0.923, seed0 160000 step 达到 0.915, ABC 扩展训练在 120000 step checkpoint 达到最佳 Avg Len 1.028。结果表明, 任务条件表达、ACT 动作分块、训练时长和 checkpoint 选择共同影响 D 环境泛化; 视觉距离和子任务分解也说明, zero-shot 控制需要同时考虑视觉分布与长链误差传播。